

Predicción de cancelaciones hoteleras

Modelo supervisado para anticipar reservas con riesgo antes de la estancia y apoyar decisiones de ocupación, seguimiento y overbooking controlado.

119.390

reservas brutas

32

columnas originales

+2 años

de registros

5

ML models entrenados

Fuente: Kaggle → Hotel Booking Demand



Autor

Ander Heriz


Bootcamp de Data Science
de The Bridge

Presentacion DS - Proyecto ML

El dataset permite aprendizaje supervisado real, con un target suficientemente representado

Target: is_canceled (clasificación binaria)

No cancelada  62.7%

Cancelada  37.3%

La clase positiva no es minoritaria extrema, pero sí obliga a mirar precisión, recall y F1; la accuracy sola ocultaría errores de negocio.

Objetivo

Predecir si una reserva será cancelada antes de la estancia.

Volumen y variables tras limpieza

118.564

filas

34

columnas

80/20

split test

Raw

119.390 x 32

Clean

118.564 x 34

Train/Test

94.851 / 23.713


25 numéricas

9 categóricas

estratificado

La limpieza prioriza evitar Data Leakage, controlar nulos, filtrar anomalías y evaluar duplicados

Nulos relevantes en raw



La limpieza sustituye identificadores con muchos nulos por **indicadores binarios**: has_company y has_agent.

Tres decisiones de limpieza

1. Fuga

Se eliminan reservation_status y reservation_status_date. assigned_room_type se excluye por posible información posterior.

2. Features

Se crean flags previas a la estancia: has_company, has_agent, needs_parking, special_requests e historial.


3. Anomalías

Se filtran reservas sin huéspedes, sin noches y ADR negativo.

4. Duplicados. +30K reservas duplicadas. Se evaluará al trabajar los modelos si mantenerlas o eliminarlas.


El análisis bivalente muestra diferencias claras por clase en lead_time y deposit_type

Tasa de cancelación por lead_time



La tasa de is_canceled **aumenta por tramos** de lead_time: 9,7% en 0-7 días frente a 57,1% en 181+ días.

Tasa de cancelación por deposit_type




Interpretación técnica

deposit_type separa fuertemente las clases; se usa como predictor, no como explicación causal aislada.


Variables previas a la estancia aportan señal adicional frente a is_canceled

Tasa por peticiones especiales



La tasa de is_canceled desciende al aumentar total_of_special_requests: 48,0% con 0 y 22,1% con 1.

Variables adicionales con señal



previous_cancellations y parking muestran diferencias por clase; ambas quedan como features candidatas.

La estrategia combina segmentación exploratoria con un pipeline supervisado reproducible

Pipeline supervisado




Transformaciones del pipeline

Numéricas: mediana + StandardScaler.

Catógicas: moda + OneHotEncoder.

Features: total_nights, total_guests y flags binarias.

KMeans como lectura exploratoria



El clustering no se usa como modelo final; sirve para interpretar perfiles de reservas y contrastar intuiciones del EDA.

XGBoost gana el benchmark y confirma mantener duplicados como decisión documentada

F1 por modelo inicial



Se selecciona F1 porque balancea precisión y recall en una clase positiva de negocio: cancelación.

Sensibilidad a duplicados



Decisión

Mantener duplicados queda documentado: sin identificador único no se puede probar que sean errores, y eliminarlos reduce mucho el F1.

El XGBoost tuneado captura la mayoría de cancelaciones con buen equilibrio precision-recall

0.881

Accuracy

0.830

Precision

0.856

Recall

0.842

F1

0.953

ROC-AUC

Matriz de confusión en test

		Predicción	
Real	No cancela	13.324	Falsa alarma 1554
	Riesgo perdido	1274	Cancelación 7561

Tuning y configuración final

XGB base

F1 0,798

RandomizedS
earchCV

optimiza F1

GridSearchCV

optimiza F1


Fine tuning

F1 0,842

XGBoost, parametros finales → n_estimators=700 | max_depth=10 | learning_rate=0.11 | scale_pos_weight=1.68 | reg_alpha=1, reg_lambda=0.5

Las variables más importantes apuntan a política de reserva y señales de compromiso

Importancia agrupada por variable



Importancia predictiva **no significa causalidad**.
Una variable puede ayudar a separar clases sin ser la causa de la cancelación.

1. Señal dominante

deposit_type concentra gran parte de la separación del modelo.

2. Compromiso

parking, peticiones e historial reducen o elevan el riesgo observado.

Antes de producción, el modelo debe validar trazabilidad, generalización y costes

Tres controles técnicos prioritarios

No son conclusiones de negocio: son validaciones pendientes antes de defender uso real.

■ Identificador / duplicados

Añadir booking_id o una regla auditable para separar duplicados reales de reservas similares.

■ Validación temporal

Entrenar con histórico y evaluar en fechas posteriores para simular generalización futura.

■ Umbral de decisión

Ajustar el threshold con costes de FP/FN; 0,5 no tiene por qué ser el punto óptimo.

Gracias!!

Turno de preguntas

Predicción de cancelaciones hoteleras · Presentación técnica ML



Autor

Ander Heriz

Bootcamp de Data Science
de The Bridge

Presentacion DS - Proyecto ML